

# Linguaggi Formali e Traduttori

## 4.1 Parsing top-down e grammatiche LL(1).

- Sommario
- Strategia per il parsing top-down
- Stringhe annullabili (NULL)
- Esempi di stringhe annullabili
- Inizi di una stringa (FIRST)
- Come calcolare FIRST
- Esempi di calcolo di FIRST
- Seguiti di una variabile (FOLLOW)
- Come calcolare FOLLOW
- Esempi di calcolo di FOLLOW
- Insiemi guida
- Grammatiche LL(1)
- Esempio: espressioni aritmetiche
- Esercizi

È proibito condividere e divulgare in qualsiasi forma i materiali didattici caricati sulla piattaforma e le lezioni svolte in videoconferenza: ogni azione che viola questa norma sarà denunciata agli organi di Ateneo e perseguita a termini di legge.

# Sommario

## Problema

- Data una grammatica  $G = (V, T, P, S)$  e una stringa  $w \in T^*$ , determinare se

$$S \Rightarrow \alpha_1 \Rightarrow \alpha_2 \Rightarrow \dots \Rightarrow w$$

o, equivalentemente, se esiste un albero sintattico di  $G$  con radice  $S$  e prodotto  $w$ .

- La **costruzione dell'automa** corrispondente a  $G$  produce un PDA non deterministico.
- Per alcune  $G$  sappiamo che **non è possibile trovare un DPDA**.

## In questa lezione

- Identifichiamo una famiglia di grammatiche libere per le quali è possibile costruire riconoscitori (parser) deterministici, cioè che non fanno uso di backtracking.
- Questi parser sono detti **top-down** perché costruiscono l'albero sintattico di  $w$  dalla radice (top) verso le foglie (down) o, equivalentemente, cercano una derivazione sinistra per  $w$ .

# Strategia per il parsing top-down

Data una grammatica  $G = (V, T, P, S)$  e una stringa  $w \in T^*$ , il parser cerca di ottenere una derivazione a sinistra  $S \Rightarrow_{lm}^* w$  in cui, al passo  $i$ , il parser sa che

$$S \Rightarrow_{lm}^* uA\beta$$

e deve stabilire se

$$uA\beta \Rightarrow_{lm}^* w$$

Ci sono due casi da considerare:

- Se  $u$  non è prefisso di  $w$ , allora il parser **rifiuta**  $w$ .
- Se  $w = uav$ , allora il parser deve **scegliere** una produzione per riscrivere  $A$

$$A \rightarrow \alpha_1 \mid \dots \mid \alpha_n$$

e per farlo può usare  $a$  come “guida”, a patto che tale simbolo identifichi univocamente l' $\alpha_i$  tale che  $\alpha_i\beta \Rightarrow_{lm}^* av$ .

Per ogni produzione  $A \rightarrow \alpha_i$  occorre saper calcolare gli insiemi di simboli terminali che possono **iniziare** le stringhe derivate da  $\alpha_i\beta$  e richiedere che tali insiemi siano disgiunti.

# Stringhe annullabili (NULL)

## Definizione

Data una grammatica  $G = (V, T, P, S)$ , diciamo che  $\alpha \in (V \cup T)^*$  è annullabile, e scriviamo  $\text{NULL}(\alpha)$ , se e solo se  $\alpha \Rightarrow_G^* \varepsilon$ , ovvero se  $\alpha$  può essere riscritta nella stringa vuota.

## Come determinare se una stringa è annullabile

- (1) Se  $\text{NULL}(X_1), \dots, \text{NULL}(X_n)$ , allora  $\text{NULL}(X_1 \cdots X_n)$ .
- (2) Se esiste una produzione  $A \rightarrow \alpha \in P$  e  $\text{NULL}(\alpha)$ , allora  $\text{NULL}(A)$ .

## Note

- Come caso particolare di (1) quando  $n = 0$  abbiamo  $\text{NULL}(\varepsilon)$ .
- Combinando (1) e (2) abbiamo che  $A \rightarrow \varepsilon \in P$  implica  $\text{NULL}(A)$ .
- Una stringa che contiene simboli terminali non è mai annullabile.

# Esempi di stringhe annullabili

$$A \rightarrow a \mid Bc$$

$$B \rightarrow \varepsilon \mid bB$$

$$C \rightarrow d \mid Cc \mid BB$$

$$B \rightarrow \text{NULL}(B)$$

$$BB \rightarrow \text{NULL}(BB)$$

# Esempi di stringhe annullabili

$$A \rightarrow a \mid Bc$$

$$B \rightarrow \varepsilon \mid bB$$

$$C \rightarrow d \mid Cc \mid BB$$

- Da  $\text{NULL}(\varepsilon)$  e dalla produzione  $B \rightarrow \varepsilon$  deduciamo  $\text{NULL}(B)$ .
- Da  $\text{NULL}(B)$  e dalla produzione  $C \rightarrow BB$  deduciamo  $\text{NULL}(C)$ .
- Da  $\text{NULL}(B)$  e  $\text{NULL}(C)$  deduciamo  $\text{NULL}(BC)$ .
- Da  $\neg\text{NULL}(a)$  e  $\neg\text{NULL}(Bc)$  deduciamo  $\neg\text{NULL}(A)$ .

# Inizi di una stringa (FIRST)

## Definizione

Data una grammatica  $G = (V, T, P, S)$  e una stringa  $\alpha \in (V \cup T)^*$ , indichiamo con **FIRST**( $\alpha$ ) gli inizi di  $\alpha$ , ovvero l'insieme dei simboli terminali che possono trovarsi all'inizio delle stringhe derivate da  $\alpha$ . Formalmente:

$$\text{FIRST}(\alpha) \stackrel{\text{def}}{=} \{a \in T \mid \alpha \Rightarrow_G^* a\beta\}$$

## Attenzione


Il libro di testo usa un'unica funzione **FIRST**<sub>libro</sub> che combina **NULL** e **FIRST** così:

$$\text{FIRST}_{\text{libro}}(\alpha) = \begin{cases} \text{FIRST}(\alpha) \cup \{\varepsilon\} & \text{se } \text{NULL}(\alpha) \\ \text{FIRST}(\alpha) & \text{altrimenti} \end{cases}$$

In pratica, l'approccio seguito dal libro ammette il simbolo speciale  $\varepsilon$  tra gli inizi di  $\alpha$  per indicare il fatto che  $\alpha$  è annullabile. Noi abbiamo definito un predicato **NULL**( $\alpha$ ) apposito mentre **FIRST**( $\alpha$ ) contiene solo simboli terminali.

# Come calcolare FIRST

È possibile calcolare  $\text{FIRST}(\alpha)$  per induzione su  $\alpha$ , usando le seguenti regole:


$$\begin{aligned}\text{FIRST}(\varepsilon) &= \emptyset \\ \text{FIRST}(a) &= \{a\} \\ \text{FIRST}(A) &= \bigcup_{A \rightarrow \alpha} \text{FIRST}(\alpha) \\ \text{FIRST}(X\alpha) &= \begin{cases} \text{FIRST}(X) \cup \text{FIRST}(\alpha) & \text{se } \text{NULL}(X) \\ \text{FIRST}(X) & \text{altrimenti} \end{cases}\end{aligned}$$

## Attenzione

Applicando le regole qui sopra, può capitare di arrivare a equazioni della forma

$$\text{FIRST}(A) = \text{FIRST}(A) \cup \mathcal{S}$$

dove  $\mathcal{S}$  è un insieme di terminali. Questa equazione si può semplificare a

$$\text{FIRST}(A) = \mathcal{S}$$

in quanto siamo interessati a ottenere il più piccolo insieme di terminali con la proprietà descritta nella slide precedente.



# Esempi di calcolo di FIRST

$S \rightarrow Ac \mid Ba$

$A \rightarrow \varepsilon \mid a$

$B \rightarrow b$

$C \rightarrow a \mid Cb$

$D \rightarrow \varepsilon \mid d \mid Db$

# Esempi di calcolo di FIRST

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

## Variabili annullabili

- $\text{NULL}(A)$
- $\text{NULL}(D)$

## Calcolo di FIRST di tutte le variabili

- $\text{FIRST}(B) = \text{FIRST}(b) = \{b\}$
- $\text{FIRST}(A) = \text{FIRST}(\varepsilon) \cup \text{FIRST}(a) = \{a\}$
- $\text{FIRST}(S) = \text{FIRST}(Ac) \cup \text{FIRST}(Ba) = \text{FIRST}(A) \cup \text{FIRST}(c) \cup \text{FIRST}(B) = \{a, b, c\}$
- $\text{FIRST}(C) = \text{FIRST}(a) \cup \text{FIRST}(Cb) = \{a\} \cup \text{FIRST}(C) = \{a\}$
- $\text{FIRST}(D) = \text{FIRST}(\varepsilon) \cup \text{FIRST}(d) \cup \text{FIRST}(Db) = \{d\} \cup \text{FIRST}(D) \cup \text{FIRST}(b) = \{b, d\}$

# Seguiti di una variabile (FOLLOW)

## Definizione

Data una grammatica  $G = (V, T, P, S)$  e una variabile  $A \in V$ , indichiamo con  $\text{FOLLOW}(A)$  i **seguiti** di  $A$ , ovvero l'**insieme dei simboli terminali che possono seguire  $A$  in una forma sentenziale**. Formalmente:



$$\text{FOLLOW}(A) \stackrel{\text{def}}{=} \{a \in T \mid S \Rightarrow_G^* \alpha A a \beta\}$$

## Attenzione

- Per convenzione aggiungeremo una sentinella  $\$$  ai seguiti del simbolo iniziale  $S$ .
- In questo modo il parser può capire quando è arrivato alla fine della stringa da riconoscere.

# Come calcolare FOLLOW

Il calcolo di **FOLLOW** si effettua in due fasi.

## Fase 1

In questa fase si annotano relazioni di appartenenza ed inclusione insiemistica secondo il seguente algoritmo:

- Annotare  $\$ \in \text{FOLLOW}(S)$ .
- Ripetere i passi seguenti per ogni produzione e per ogni variabile nel corpo di queste:
  1. Se  $A \rightarrow \alpha B \beta$ , allora annotare  $\text{FIRST}(\beta) \subseteq \text{FOLLOW}(B)$ .
  2. Se  $A \rightarrow \alpha B \beta$  e  $\text{NULL}(\beta)$ , allora annotare  $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$ .

Caso particolare di (2): se  $A \rightarrow \alpha B$ , allora annotare  $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$ .

## Fase 2

Si determinano i seguiti propagando i simboli terminali (e  $\$$ ) rispettando l'ordine delle inclusioni insiemistiche  $\subseteq$  che sono state annotate.

Per grammatiche complesse può essere utile fare una tabella con due colonne, l'elenco di tutte le variabili nella prima ed i seguiti corrispondenti alle variabili nella seconda.

# Esempi di calcolo di FOLLOW

$S \rightarrow Ac \mid Ba$

$A \rightarrow \varepsilon \mid a$

$B \rightarrow b$

$C \rightarrow a \mid Cb$

$D \rightarrow \varepsilon \mid d \mid Db$

# Esempi di calcolo di FOLLOW

$$S \rightarrow Ac \mid Ba$$

$$A \rightarrow \varepsilon \mid a$$

$$B \rightarrow b$$

$$C \rightarrow a \mid Cb$$

$$D \rightarrow \varepsilon \mid d \mid Db$$

Fase 1

- $\$ \in \text{FOLLOW}(S)$
- $\text{FIRST}(c) \subseteq \text{FOLLOW}(A)$
- $\text{FIRST}(a) \subseteq \text{FOLLOW}(B)$
- $\text{FIRST}(b) \subseteq \text{FOLLOW}(C)$
- $\text{FIRST}(b) \subseteq \text{FOLLOW}(D)$

Fase 2

$X$	$\text{FOLLOW}(X)$
$S$	$\{\$ \}$
$A$	$\{c\}$
$B$	$\{a\}$
$C$	$\{b\}$
$D$	$\{b\}$

# Insiemi guida

## Definizione

Data una grammatica  $G = (V, T, P, S)$  e una produzione  $A \rightarrow \alpha$ , indichiamo con  $\text{GUIDA}(A \rightarrow \alpha)$  l'insieme guida di  $A \rightarrow \alpha$ , ovvero l'insieme

$$\text{GUIDA}(A \rightarrow \alpha) \stackrel{\text{def}}{=} \begin{cases} \text{FIRST}(\alpha) \cup \text{FOLLOW}(A) & \text{se } \text{NULL}(\alpha) \\ \text{FIRST}(\alpha) & \text{altrimenti} \end{cases}$$

## Intuizione

Un parser predittivo che sceglie di riscrivere la variabile  $A$  usando la produzione  $A \rightarrow \alpha$  si aspetta di leggere nella stringa di input uno dei simboli nell'insieme guida di  $A \rightarrow \alpha$ .

Sono due i casi da considerare:

1. Il simbolo è uno degli inizi di  $\alpha$ , oppure
2.  $\alpha$  è annullabile ed il simbolo è uno dei seguiti di  $A$ .

# Grammatiche LL(1)

## Definizione

Diciamo che una grammatica  $G = (V, T, P, S)$  è LL(1) se, per ogni coppia di produzioni distinte  $A \rightarrow \alpha$  e  $A \rightarrow \beta$  in  $P$ , abbiamo che

$$\text{GUIDA}(A \rightarrow \alpha) \cap \text{GUIDA}(A \rightarrow \beta) = \emptyset$$

## Intuizione

Noto il simbolo da riscrivere  $A$ , note le produzioni  $A \rightarrow \beta_1 \mid \dots \mid \beta_n$  e noto il prossimo simbolo terminale  $a$  nella stringa da riconoscere, in una grammatica LL(1) esiste al massimo una produzione “giusta” tale che  $a \in \text{GUIDA}(A \rightarrow \beta_i)$  dunque il parser predittivo identifica univocamente la produzione  $A \rightarrow \beta_i$  a partire da  $a$ .

## Cosa c'è nel nome LL(1)

- L  $\rightarrow$  la stringa in input viene analizzata da sinistra (left) a destra;
- L  $\rightarrow$  il parser cerca di costruire una derivazione canonica sinistra (leftmost);
- 1  $\rightarrow$  il parser usa un solo simbolo terminale della stringa per scegliere la produzione.



# Esempio: espressioni aritmetiche

$$\begin{aligned} E &\rightarrow TE' \\ E' &\rightarrow +TE' \mid \epsilon \quad \text{NULL}(E') \\ T &\rightarrow FT' \\ T' &\rightarrow *FT' \mid \epsilon \quad \text{NULL}(T') \\ F &\rightarrow (E) \mid \text{id} \end{aligned}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{+\} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{*\} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{)\} = \text{FIRST}()) \subseteq \text{FOLLOW}(E)$

# Esempio: espressioni aritmetiche

$$E \rightarrow TE'$$

$$E' \rightarrow +TE' \mid \varepsilon \quad \text{NULL}(E')$$

$$T \rightarrow FT'$$

$$T' \rightarrow *FT' \mid \varepsilon \quad \text{NULL}(T')$$

$$F \rightarrow (E) \mid \text{id}$$

$$\text{FIRST}(E) = \text{FIRST}(T) = \{ (, \text{id} \}$$

$$\text{FIRST}(E') = \{ + \}$$

$$\text{FIRST}(T) = \text{FIRST}(F) = \{ (, \text{id} \}$$

$$\text{FIRST}(T') = \{ * \}$$

$$\text{FIRST}(F) = \{ (, \text{id} \}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{ + \} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{ * \} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{ ) \} = \text{FIRST}(F) \subseteq \text{FOLLOW}(E)$

# Esempio: espressioni aritmetiche

$$\begin{aligned}E &\rightarrow TE' \\E' &\rightarrow +TE' \mid \varepsilon \quad \text{NULL}(E') \\T &\rightarrow FT' \\T' &\rightarrow *FT' \mid \varepsilon \quad \text{NULL}(T') \\F &\rightarrow (E) \mid \text{id}\end{aligned}$$

$$\begin{aligned}\text{FIRST}(E) &= \text{FIRST}(T) = \{ (, \text{id} \} \\ \text{FIRST}(E') &= \{ + \} \\ \text{FIRST}(T) &= \text{FIRST}(F) = \{ (, \text{id} \} \\ \text{FIRST}(T') &= \{ * \} \\ \text{FIRST}(F) &= \{ (, \text{id} \}\end{aligned}$$

- $\$ \in \text{FOLLOW}(E)$
- $\{ + \} = \text{FIRST}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\{ * \} = \text{FIRST}(T') \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(F)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$
- $\{ ) \} = \text{FIRST}()) \subseteq \text{FOLLOW}(E)$

$X$	$\text{FOLLOW}(X)$
$E$	$\$, )$
$E'$	$\$, )$
$T$	$\$, ), +$
$T'$	$\$, ), +$
$F$	$\$, ), +, *$

# Esercizi

1. Calcolare gli insiemi guida della grammatica nella [slide 14](#). La grammatica è LL(1)?
2. Calcolare gli insiemi guida della seguente grammatica e determinare se è LL(1).

$$A \rightarrow BC \mid D$$

$$B \rightarrow \varepsilon \mid a$$

$$C \rightarrow b \mid cCc$$

$$D \rightarrow \varepsilon \mid CD$$

3. Ripetere l'esercizio precedente per la grammatica

$$S \rightarrow \textbf{if } E \textbf{ then } SS' \textbf{ fi} \mid \textbf{skip}$$

$$S' \rightarrow \textbf{else } S \mid \varepsilon$$

$$E \rightarrow \textbf{true} \mid \textbf{false}$$

in cui  $S$ ,  $S'$  ed  $E$  sono variabili e **if**, **then**, ... sono terminali.

4. Ripetere l'esercizio precedente dopo aver rimosso il terminale **fi** dalla grammatica.